Redes convolucionales

Jocelyn Dunstan Escudero

jdunstan@uc.cl

Departamento de Ciencia de la Computación
& Instituto de Matemática Computacional

Pontificia Universidad Católica de Chile

29 de octubre de 2025

Objetivos

- Distinguir los elementos básicos de una red convolucional.
- Entender el concepto de convolución.
- Calcular dimensiones de la salida de una capa convolucional.

Recomendación: Cursos de Domingo Mery

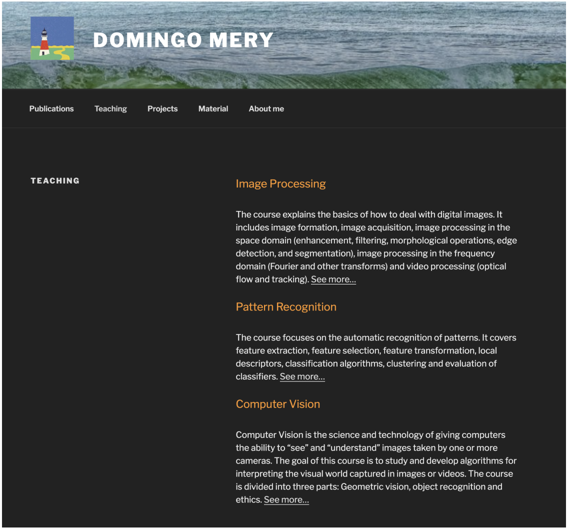

https://domingomery.ing.uc.cl/teaching/

Recomendación: Clase de redes convolucionales del MIT

6.874, 6.802, 20.390, 20.490, HST.506
Deep Learning in the Life Sciences

Lecture 3:
Convolutional Neural Networks
Prof. Manolis Kellis

Slides credit: **6.S191**, Dana **Erlich**, Param Vir **Singh**, David **Gifford**, Alexander **Amini**, Ava **Soleimany**, **@TessFerrandez**'s totally awesome **Coursera** Notes, and many more outstanding online resources

Massachusetts Institute of Technology

http://mit6874.github.io

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

https://www.youtube.com/watch?v=r5nXYc2wYvI&list=PLypiXJdtIca5sxV7aE3-PS9fYX3vUdIOX&index=5

Hasta ahora hemos visto solo redes fully connected

¿Cuántos parámetros tengo que aprender en esta red?

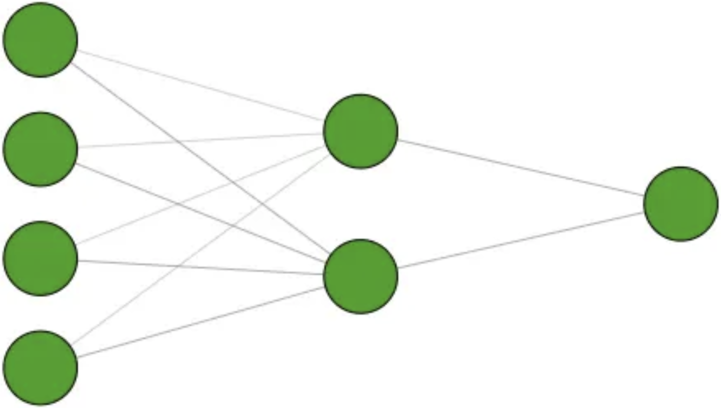

¿Y en esta?

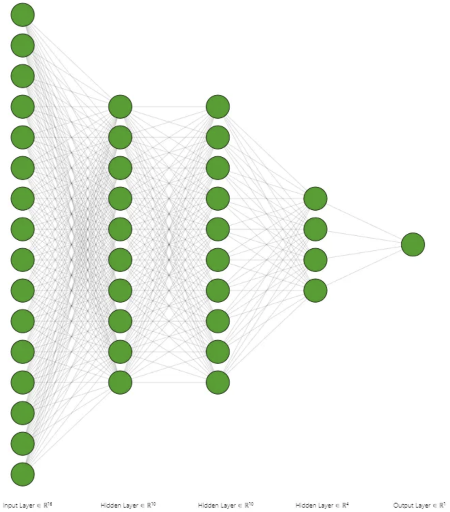
Input Layer ∈ ℝ¹⁶
Hidden Layer ∈ ℝ¹⁰
Hidden Layer ∈ ℝ¹⁰
Hidden Layer ∈ ℝ⁴
Output Layer ∈ ℝ¹

Contando parámetros en una red *fully connected*

1 Go to wooclap.com

2 Enter the event code in the top banner

Event code
NIFLJB

¿Qué vemos cuando vemos?

¿Qué vemos cuando vemos?

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

CNN inspiration in the 50s/60s: human/animal visual cortex

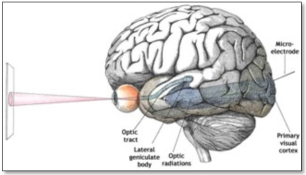

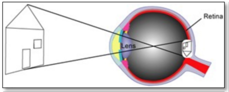

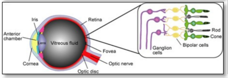

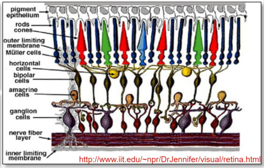

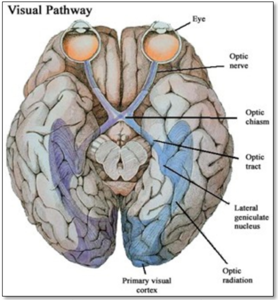

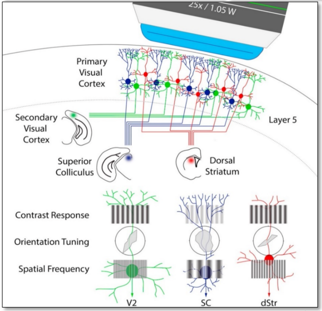

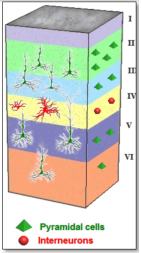

- Hubel/Wisel 1968 cat/monkey: (1) Receptive fields = local computation. (2) Simple cells = edge/orientation detectors. (3) Complex cells = position invariance/pooling
- Layers: pixels, edges (bands given slant, contrast edges), shapes, primitives, scenes
- Hierarchical abstractions, simple building blocks, local computation, learning, invariance

https://youtu.be/IOHayh06LJ4?si=4BKUxjJowytEwSYu

General "learning machine", reused widely

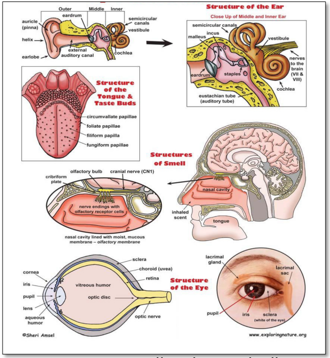

- Hearing, taste, smell, sight, touch all re-use similar learning architecture

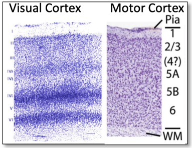

- Interchangeable circuitry
- Auditory cortex learns to 'see' if sent visual signals
- Injury area tasks shift to uninjured areas

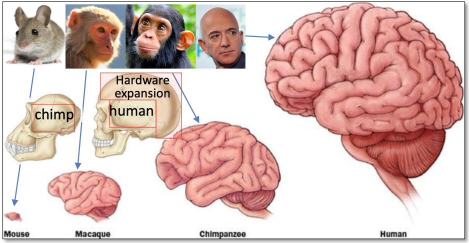

- Massive recent expanse of human brain has re-used a relatively simple but general learning architecture

- Learning not fully-general, but well-adapted to our world
- Humans co-opted this circuitry to many new applications
- Modern tasks accessible to any homo sapiens (70k years!)
- ML still similar to animals: room for architecture novelty!

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

Algoritmos de Deep Learning del Curso

- Object Classification (CNN)
- Object Detection (YOLO)
- Tracking
- Segmentation (UNet)
- GAN
- Anomaly Detection
- Transformers
- Facial Analysis

- Face detection
- Face recognition
- Face restoration
- Age recognition
- Gender recognition
- Expression recognition
- Soft attributes
- Face clustering
- Pose estimation
- Explainability

`github.com/domingomery/vision`

Redes convolucionales para clasificación

Típicos elementos en una red convolucional para clasificación

- Capa convolucional
- Uso de RELU como función de activación
- Capa de pooling (*max or mean*)
- Capa Fully connected y Softmax.

Idea general detrás de la convolución

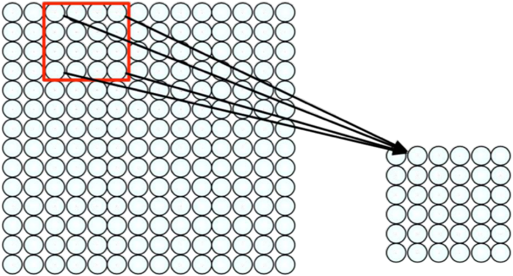

Idea general detrás de la convolución

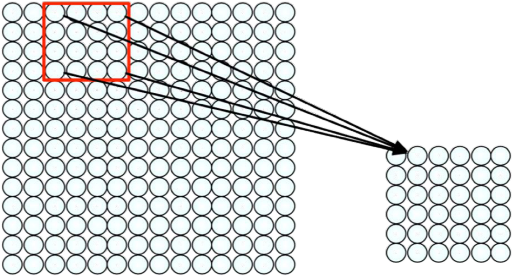

- Aplicar un set de pesos (filtros) moviéndose dentro de la imagen. Aplicar el filtro es hacer una suma ponderada
- Aplicar el sesgo o bias
- Aplicar la función de activación (en general no-lineal)

Filtros o kernels

Aplicar el filtro es multiplicar elemento a elemento y luego sumar

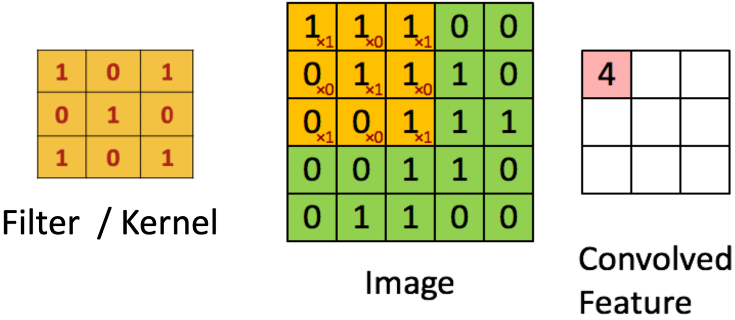

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

Ejemplo de detección de bordes (*edges*)

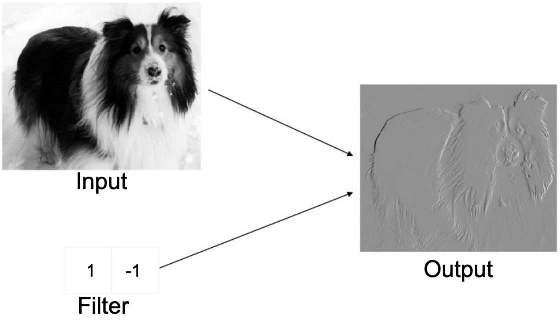

(Goodfellow 2016)

Filtro para (*sharpen*)

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

En aprendizaje profundo, la red aprende los valores para los filtros, y se aplica el mismo filtro sobre toda la imagen

Convolución de 3x3 en una imagen de 5x5 usando un *padding* de 1

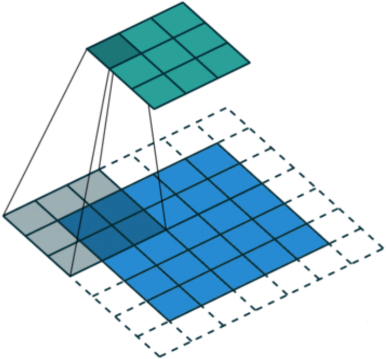

Stride es el tamaño del paso con que el filtro recorre la imagen.

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

Convolución en una imagen RGB

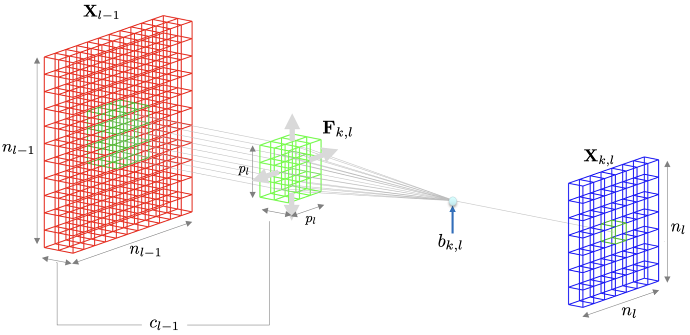

https://github.com/domingomery/vision/blob/master/clases/Cap03_DeepLearning/presentations/CV03_CNN.pptx

Convolución en una imagen RGB

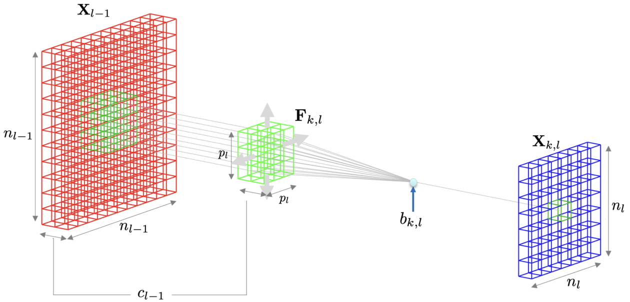

$$\mathbf{X}_{k,l} = \mathbf{X}_{l-1} * \mathbf{F}_{k,l} + b_{k,l} \quad \text{for } k = 1 \ldots m_l$$

`https://github.com/domingomery/vision/blob/master/clases/Cap03_DeepLearning/presentations/CV03_CNN.pptx`

Dimensiones de salida de la capa de convolución

$$O = \frac{I - F + P_{\text{start}} + P_{\text{end}}}{S} + 1$$

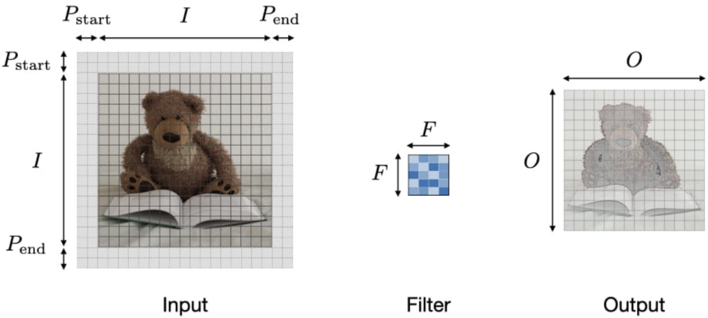

https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-convolutional-neural-networks

Típicos elementos en una red convolucional para clasificación

- Capa convolucional
- Uso de RELU como función de activación
- Capa de pooling (*max or mean*
- Capa Fully connected y Softmax.

Después de cada capa convolucional aplicaremos la función de activación (usualmente RELU)

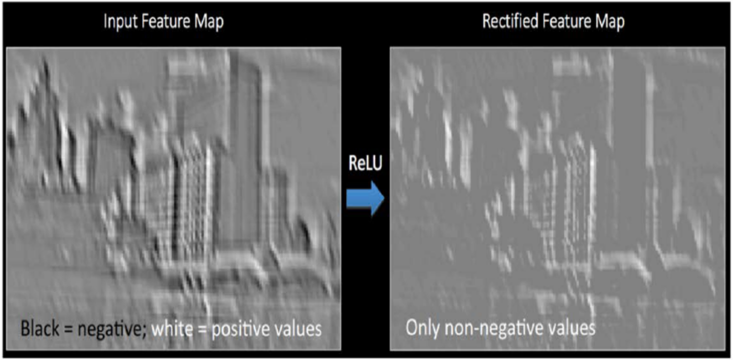

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

Típicos elementos en una red convolucional para clasificación

- Capa convolucional
- Uso de RELU como función de activación
- Capa de pooling (*max or mean*)
- Capa Fully connected y Softmax.

Pooling

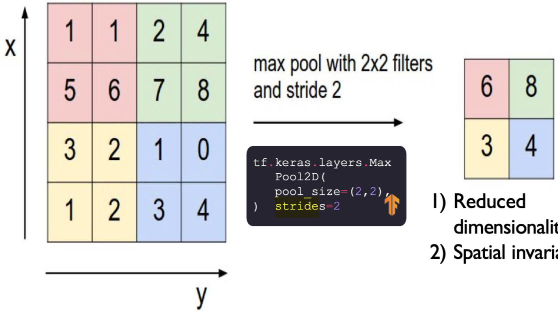

1) Reduced dimensionality
2) Spatial invariance

Max Pooling, average pooling

Pooling

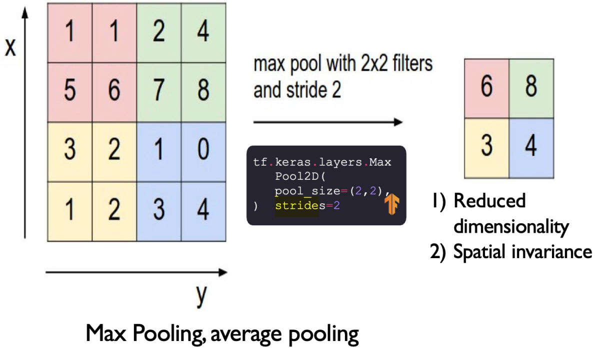

¿Necesito aprender parámetros para esta capa?

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

Típicos elementos en una red convolucional para clasificación

- Capa convolucional
- Uso de RELU como función de activación
- Capa de pooling (*max or mean*)
- Capa Fully connected y Softmax.

Softmax entrega la probabilidad de cada clase

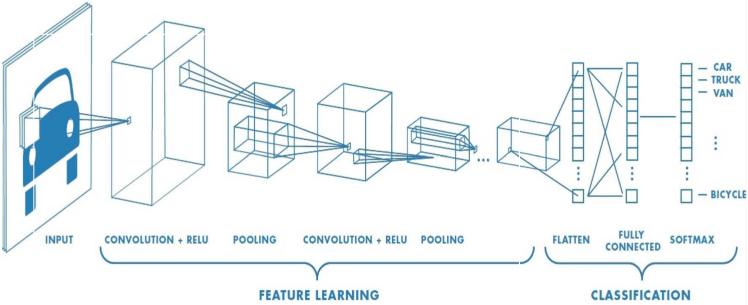

$$\mathrm{softmax}(y_i) = \frac{e^{y_i}}{\sum_j e^{y_j}}$$

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

Resumen

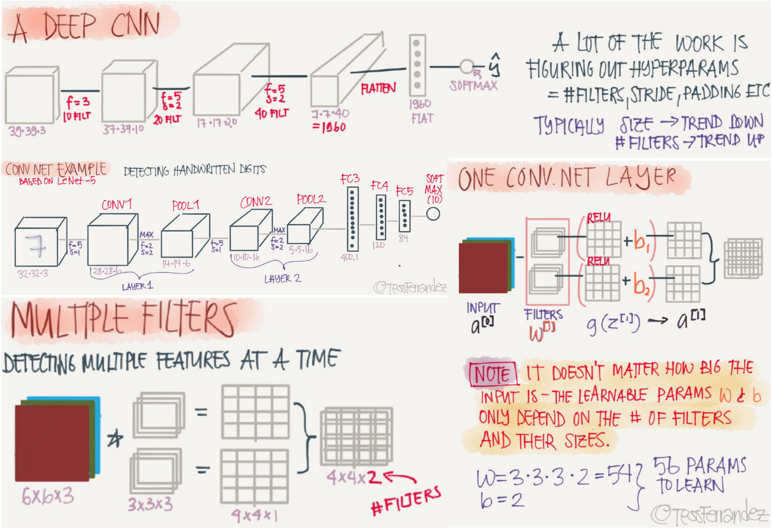

https://mit6874.github.io/assets/sp2021/slides/l03.pdf

Distintas capas, distinto nivel de abstracción

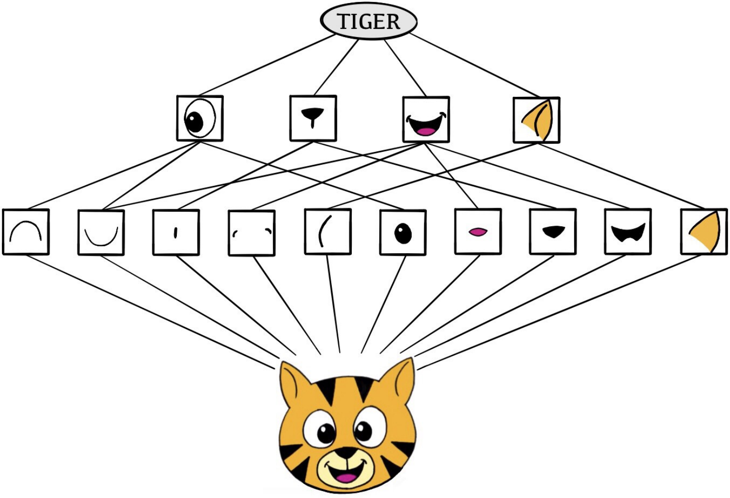

https://www.statlearning.com/